

INFORME

Evaluación práctica de la Unidad 1: Reconociendo lo aprendido

Grupo 7

Miembros

Manuela Osorio Galván

Nicolas Steven Palacios Pabon

Caso de Estudio: Empresa “Gaseosas Poderosas”


En base a la información suministrada, debe construir un modelo conceptual y un modelo lógico de base datos que represente el Caso de Estudio, realizar todo el proceso ETL, limpieza, visualización y análisis de los resultados. Cada sección a continuación especifica las instrucciones para realizar la actividad.

NOTA: Recuerde eliminar los comentarios de ayuda (azules y en itálica) después de responder el ítem

1.- Descripción de la Tarea

El trabajo se trata de migrar la información de una empresa llamada "Gaseosas Poderosas" ya que tenía la base de datos en el formato CSV con toda la información mediante un archivo de Python, para garantizar la migración correcta de los datos se hizo limpieza y corrección de datos.

2.- Diagrama de Entidad -Relación (Diagrama de Chen)



3.- Diccionario de Datos

Tabla Regiones

Campo	Tipo Dato	Tamaño	Valores Permitidos	PK	FK	Única	Relación
Id_Región	Integer	-	1 a 6	Si	No	Si	-
Nombre	varchar	70	Nombre Region	No	No	-	-

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 103
Periodo 2026-2
Profesor: Walter H Arboleda M

Tabla Departamentos

Campo	Tipo Dato	Tamaño	Valores Permitidos	PK	FK	Única	Relación
Id_departamento	Integer	-	Código generado	Si	No	Si	-
Nombre	varchar	70	Nombre del departamento	No	No	-	-
Codigo_Dane	varchar	10	Codigo DANE original	No	No	-	-
Codigo_Region	Integer	-	1 a 6	No	No	-	-

Tabla Municipios

Campo	Tipo Dato	Tamaño	Valores Permitidos	PK	FK	Única	Relación
Id_departamento	Integer	-	-	No	No	-	Referencia a departamentos.id_departameto
Id_Municipio	Integer	-	Código generado	Si	No	Si	-
Nombre	varchar	70	Nombre del municipio	No	No	-	-
Codigo_Dane	varchar	10	Código Dane original	No	No	Si	-

Tabla Productos

Campo	Tipo Dato	Tamaño	Valores Permitidos	PK	FK	Única	Relación
Id_Producto	Integer	-	1 a 4	Si	No	No	-
Nombre	varchar	20	Colombianita, Manzaloca, Mangoson, Naranjita	No	No	-	-
Precio	Integer	-	Entero	No	No	-	-

Tabla Operaciones

Campo	Tipo Dato	Tamaño	Valores Permitidos	PK	FK	Única	Relación
Id_Registro	Integer	-	1 a 10000	Si	NO	No	-
Id_Departamento	Integer	-	-	No	Si	-	Referencia a departamentos.id_departamento
Id_Municipio	Integer	-	-	No	Si	-	Referencia a municipios.id_municipio
Id_Producto	Integer	-	1 a 4	No	Si	-	Referencia a productos.id_producto
Fecha	varchar	10	Formato AAAA-MM-DD	No	No	-	-
Cantidad	Integer	-	Entero ≥ 0	No	No	-	-
Estado	varchar	1	Valor observado: 'F'	No	No	-	-
Id_Region	Integer	-	1 a 6	No	Si	-	Referencia a regiones.id_region


I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 103
Periodo 2026-2
Profesor: Walter H Arboleda M


Tabla Temporal

Campo	Tipo Dato	Tamaño	Valores Permitidos	PK	FK	Única	Relación
Codigo_dep	Varchar	10	Código DANE departamento	No	No	No	-
Codigo_mun	varchar	10	Código DANE municipio	No	No	-	-
Codigo_region	Integer	-	1 a 6	No	No	-	-
Departamento	Text	-	Nombre departamento	No	No	-	-
Municipio	Text	-	Nombre municipio	No	No	-	-
Región	Text	-	Nombre región	No	No	-	-

4.- Corrida del algoritmo ETL


En breves palabras el algoritmo ETL es un algoritmo que lo que hace es extraer la información del archivo CSV, información como departamentos, región, municipios y códigos del DANE y los inserta en la base de datos previamente indicada en los parámetros de la conexión, extrae la información de los departamentos según el DANE, los resultados son la carga de municipios con sufijo id de departamento, id de municipio, nombre, código y los datos de región, departamento y códigos del DANE.






5- Modificar el algoritmo ETL para incluir dato de región.

Se agregó el campo id_region a la tabla operaciones mediante alter table, y se valorizó cruzando cada registro con su departamento correspondiente en la tabla departamentos.





I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 103
Periodo 2026-2
Profesor: Walter H Arboleda M

6.- Detectar registros con problemas. Transformación de datos (limpieza, modificación, imputación)

Tipo de problema	Número Registro	Campo (BD)	Problema detectado	Solución
Tipo A	10001 11599 12110 13945 14368 15955 16558 17125 18056 19680	Fecha	Mes sin cero (2024-8-21) Año con 2 dígitos (24-02-08) Año con 3 dígitos (024-07-17) Orden invertido DD-MM-AAAA Orden AA-DD-MM Orden ambiguo DD-MM-AA Orden invertido DD-MM-AAAA	Rellenar el mes Ordenar y rellenar el año
Tipo B	13161 15412 17528 10225 19181	Cantidad	Cantidad de producto en cero	Mirar la venta del más vendido en el municipio y agregar un promedio de la cantidad
Tipo C	15208 18126 10014 11907 19538	Cantidad	Cantidad negativa -175	Solo cambiar el signo de la cantidad, es decir, queda en 175
Tipo D	10326 12188 14020 16635 18469	Id_departamento	Departamento en cero	Como el municipio tenía su id, se relaciona y de ahí se saca el departamento
Tipo E	10686 19195 18911 17341 11734	Id_producto	Código de producto en 0 en el municipio de "Tamesis"	Cambiar el código del producto de 0 por 4 que es el código de "Naranjita"

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 103
Periodo 2026-2
Profesor: Walter H Arboleda M

7.- Tabla de consultas SQL


#	Descripción	Consulta SQL
7.1	Seleccionar los 8 departamentos con mayor volumen de ventas (monto) de productos ordenados de mayor a menor. Datos solicitados: nombre de departamento y monto total por departamento de todos los productos. Nota: Recuerde que tiene agrupar por departamento	https://github.com/nicolastevv/ScriptsBigData/blob/main/ScriptsBigData/7.1OchoDepartamentos.sql
7.2	Seleccionar los 15 municipios con mayor cantidad de productos vendidos en el departamento de Antioquia ordenados de mayor a menor. Datos solicitados: nombre municipio y cantidad total por municipio. Nota: Recuerde que tiene agrupar por municipio	https://github.com/nicolastevv/ScriptsBigData/blob/main/ScriptsBigData/7.2QuinceMunicipios.sql
7.3	Seleccionar los 5 departamentos con mayor cantidad de gaseosas vendidas del producto “MANZALOCA” ordenados de mayor a menor. Datos solicitados: nombre de departamento y cantidad total por departamento. Nota: Recuerde que tiene agrupar por departamento y filtrar por el producto.	https://github.com/nicolastevv/ScriptsBigData/blob/main/ScriptsBigData/7.3CincoDepartamentosManzaloca.sql
7.4	Seleccione los 5 municipios con el menor monto de ventas de gaseosas ordenados de menor a mayor. Datos solicitados: nombre del departamento al que pertenece, nombre municipio y monto total de ventas por municipio. Nota: Recuerde que tiene agrupar por municipio	https://github.com/nicolastevv/ScriptsBigData/blob/main/ScriptsBigData/7.4CincoMunicipiosMenorMontoVentas.sql
7.5	Consultar la cantidad de gaseosas vendidas de cada producto por cada región ordenados de mayor a menor.	https://github.com/nicolastevv/ScriptsBigData/blob/main/ScriptsBigData/7.5GaseosasVendidasPorIdRegion.sql
7.6	Consultar el total del monto de ventas de cada producto en Antioquia de mayor a menor.	https://github.com/nicolastevv/ScriptsBigData/blob/main/ScriptsBigData/7.6VentasDeCadaProductoEnAntioquiaMayorAMenor.sql

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 103
Periodo 2026-2
Profesor: Walter H Arboleda M

8.- Gráficos

8.1.- Gráfico de Pareto que muestra los resultados de la consulta #7.1.

8.1.1.- Resultados de la consulta.



The screenshot shows a PostgreSQL query window with the following SQL query:


```
1 SELECT departamento, SUM(venta) AS monto_total
2 FROM vista_operaciones
3 GROUP BY departamento
4 ORDER BY monto_total DESC
5 LIMIT 8;
```

The results are displayed in a table with two columns: 'departamento' and 'monto_total'.

departamento	monto_total
Antioquia	105759800
Boyaca	99508500
Cundinamarca	93951100
Santander	73633600
Nariño	54167600
Bolivar	40279200
Tolima	39817700
Valle del Cauca	36605600


8.1.2.- Gráfico.

Departamento	Cantidad Total
Antioquia	105.759.800
Boyaca	99.508.500
Cundinamarca	93.951.100
Santander	73.633.600
Nariño	54.167.600
Bolivar	40.279.200
Tolima	39.817.700
Valle del Cauca	36.605.600



8.2.- Gráfico de Pareto que muestra los resultados de la consulta #7.2.

8.2.1.- Resultados de la consulta.



The screenshot shows a PostgreSQL query window with the following SQL query:

```
1 SELECT municipio, SUM(cantidad) AS cantidad_total
2 FROM vista_operaciones
3 WHERE departamento = 'Antioquia'
4 GROUP BY municipio
5 ORDER BY cantidad_total DESC
6 LIMIT 15;
```


The results are displayed in a table with two columns: 'municipio' and 'cantidad_total'.

municipio	cantidad_total
Valdivia	1850
Turbo	1768
Sopetrán	1669
Nariño	1611
Caceres	1604
Amaga	1600
Frontino	1520
Puerto Berrio	1514
Anorí	1510
Dabeiba	1441
Amalfi	1430
Belmora	1412
San Pedro de Urabá	1399
Veneria	1391
Arboletes	1380

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 103
Periodo 2026-2
Profesor: Walter H Arboleda M

8.2.2.- Gráfico.

Municipio	Cantidad Total
Valdivia	1.850
Turbo	1.708
Sopetran	1.699
Nariño	1.611
Caceres	1.604
Amaga	1.600
Frontino	1.520
Puerto Berrio	1.514
Anori	1.510
Dabeiba	1.441
Amalfi	1.430
Belmira	1.412
San Pedro de Uraba	1.399



8.3.- Gráfico de Pareto que muestra los resultados de la consulta #7.3.

8.3.1.- Resultados de la consulta.


```

1 SELECT departamento, SUM(cantidad) AS cantidad_total
2 FROM vista_operaciones
3 WHERE producto = 'MANZALOCA'
4 GROUP BY departamento
5 ORDER BY cantidad_total DESC
6 LIMIT 5;
  
```

departamento	cantidad_total
Antioquia	27305
Boyaca	26577
Cundinamarca	25816
Santander	21376
Nariño	14273

8.3.2.- Gráfico.

Departamento	Cantidad Total
Antioquia	27.305
Boyaca	26.577
Cundinamarca	25.816
Santander	21.376
Nariño	14.273



I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 103
Periodo 2026-2
Profesor: Walter H Arboleda M

8.4.- Gráfico de Pareto que muestra los resultados de la consulta #7.4.

8.4.1.- Resultados de la consulta.

bigdata/postgres@PostgreSQL 18*

bigdata/postgres@PostgreSQL 18

Query Query History

```

1 SELECT departamento, municipio, SUM(venta) AS monto_total
2 FROM vista_operaciones
3 GROUP BY departamento, municipio
4 ORDER BY monto_total ASC
5 LIMIT 5;


```

Data Output Messages Notifications

	departamento character varying (70)	municipio character varying (70)	monto_total bigint
1	Valle del Cauca	Zarzal	68200
2	Cesar	Pelaya	86400
3	Boyacá	Togãti	92800
4	Córdoba	Moãtitos	94200
5	Cundinamarca	Sesquile	104200

8.4.2.- Gráfico.

Municipio	Monto Total
Zarzal	68.200
Pelaya	86.400
Togãti	92.800
Moãtitos	94.200



8.5.- Gráfico de Tortas que muestra los resultados de la consulta #7.5.

8.5.1.- Resultados de la consulta.

Query

Query History

1

2

3

4

5

6

7

8

SELECT

id_region,

producto,

SUM(cantidad) AS cantidad_vendida

FROM vista_operaciones

GROUP BY id_region, producto

ORDER BY cantidad_vendida DESC;

Data Output

Messages

Notifications

SQL

	id_region integer	producto character varying (20)	cantidad_vendida bigint
1	2	MANGOSON	83105
2	2	MANZALOCA	82590
3	2	NARANJITA	82505
4	2	COLOMBIANITA	78059
5	4	NARANJITA	47274
6	4	COLOMBIANITA	44702
7	4	MANGOSON	44699
8	6	MANGOSON	43859
9	6	COLOMBIANITA	42949
10	4	MANZALOCA	42727
11	1	COLOMBIANITA	41966
12	1	NARANJITA	41405

Query

Query History

1

2

3

4

5

6

7

8

SELECT

id_region,

producto,

SUM(cantidad) AS cantidad_vendida

FROM vista_operaciones

GROUP BY id_region, producto

ORDER BY cantidad_vendida DESC;

Data Output

Messages

Notifications


SQL

	id_region integer	producto character varying (20)	cantidad_vendida bigint
13	6	NARANJITA	39984
14	6	MANZALOCA	39871
15	1	MANGOSON	39231
16	1	MANZALOCA	38089
17	3	NARANJITA	29775
18	3	MANZALOCA	28327
19	3	MANGOSON	28248
20	3	COLOMBIANITA	27858
21	5	MANZALOCA	16444
22	5	NARANJITA	15595
23	5	COLOMBIANITA	14430
24	5	MANGOSON	14054

I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 103
Periodo 2026-2
Profesor: Walter H Arboleda M

8.5.2.- Gráfico.

Región	Producto	Monto Total
2	MANGOSON	83.105
2	MANZALOCA	82.590
2	NARANJITA	82.505
2	COLOMBIANITA	78.059
4	NARANJITA	47.274
4	COLOMBIANITA	44.702
4	MANGOSON	44.699
6	MANGOSON	43.859
6	COLOMBIANITA	42.949
4	MANZALOCA	42.727
1	COLOMBIANITA	41.966
1	NARANJITA	41.405
6	NARANJITA	39.984
6	MANZALOCA	39.871
1	MANGOSON	39.231
1	MANZALOCA	38.089
3	NARANJITA	29.775
3	MANZALOCA	28.327
3	MANGOSON	28.248
3	COLOMBIANITA	27.858
5	MANZALOCA	16.444
5	NARANJITA	15.595
5	COLOMBIANITA	14.430
5	MANGOSON	14.054



8.6.- Gráfico de Torta que muestra los resultados de la consulta #7.6.


8.6.1.- Resultados de la consulta.

Query: `SELECT producto, SUM(venta) AS monto_total FROM vista_operaciones WHERE departamento = 'Antioquia' GROUP BY producto ORDER BY monto_total DESC;`

producto	monto_total
COLOMBIANITA	35680800
MANZALOCA	27305000
MANGOSON	24820200
NARANJITA	17953800

8.6.2.- Gráfico.

Producto	Monto Total
COLOMBIANITA	35.680.800
MANZALOCA	27.305.000
MANGOSON	24.820.200
NARANJITA	17.953.800



I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 103
Periodo 2026-2
Profesor: Walter H Arboleda M

10.- Determinar el tiempo y tamaño de procesamiento de un conjunto de registros.

Cantidad de registros	Tiempo de procesamiento (milisegundos)	Tamaño tabla "tamaño" (kilobytes)	Tamaño Base de Datos "bigdata" (Kilobytes o MegaBytes)	Porcentaje de almacenamiento de "tamaño" con respecto al total de la base de datos
10.000	24419.739246368408203	696 KB	11 MB	6.18%
100.000	170331.35414123535156	6704 KB	17MB	38.5%
1.000.000	1685257.2891712188721	65000 KB	76MB	85.5%
10.000.000	11150901.35049819946	651000 KB	661 MB	96.2%

11.- Análisis de los resultados

- *¿Por qué en este departamento se vendieron más gaseosas de todas los tipos?*

Para esto nos ubicaremos en Antioquia que fue en el departamento que más ventas tuvo, con un total de 105759800 ventas, podemos sacar una conclusión y es que esta cifra de ventas se debe a las olas de calor los cuales hay días de hasta 32 grados centígrados, esto aumenta la compra de refrescos en especial gaseosas para mitigar el calor.

- *¿Por qué en este departamento tan importante se vendieron menos gaseosas que en otros departamentos con menor población?*

Para esto nos ubicaremos en el departamento del Valle del Cauca que a pesar de su densa población obtuvo tan solo 68200 ventas esto se debe a que el índice de comercio mas que todo no es gaseosas sino jugos naturales pero aun así se obtuvieron ventas significativas


- *¿Por qué estos municipios tuvieron ventas tan bajas?*

También podemos decir que estos municipios tuvieron ventas demasiado bajas por las condiciones climáticas actuales, a pesar de que el Valle del Cauca prima principalmente por tener un clima caliente en estos momentos están pasando por fuertes olas de invierno lo cual no promueve tanto la venta de gaseosas.

- *¿Qué sucedió en estos municipios que arrojaron ventas fuera de la media esperada? (Datos atípicos)*

Se tomó el dato concreto y se corrigió, es decir, por ejemplo datos negativos se toma el valor como entero positivo sin importar el signo y se corrige el dato.

12.- Diagrama de flujo del programa Python de procesamiento ETL.



I.U. PASCUAL BRAVO
ET-0155 – Fundamentos de Big Data – Grupo 103
Periodo 2026-2
Profesor: Walter H Arboleda M

13.- Conclusiones INDIVIDUALES

Conclusión Manuela: Este proyecto representó un reto importante para mí, ya que me permitió realizar una practica del proceso de ETL sobre una base de datos real en PostgreSQL. Trabajar con datos reales del DANE fue muy retador a la hora ver ser muy minucioso con los detalles del archivo, adquirí nuevos conocimientos sobre le manejo de conexiones a base de datos, el uso de tablas temporales como paso intermedio en un proceso de carga y la importancia de manejar validaciones en cada etapa. Este proyecto impacta positivamente en mi formación, por que son habilidades que se aplican directamente en proyectos reales de manejo de datos, a nivel académico, me deja un poco mas preparada para los futuros proyectos y asignaturas relacionada con la base de datos.

Conclusión Nicolas: En conclusión, el trabajo realizado impacta en mi vida académica afrontando nuevos retos como lo que son la manipulación de datos de este trabajo, el trabajar con datos del DANE y el transformar esos datos, utilizar distintos métodos para solucionar los problemas con los datos y el poder aprender de este trabajo al usar una cantidad considerada de datos.

14.- Video explicativo del desarrollo completo de la tarea por parte de los miembros del equipo

https://drive.google.com/file/d/15sUpE7eZ9b0nSML0U16FtVE8I29vvQi/view?usp=drive_link